Optimisation Pipeline IA

Faut-il mélanger les modèles d'assistance au code ?

Rapport de tests comparés : Sonnet, Opus, Codex et leurs pipelines
Bancs T3b à T10, enquête difficile, projet réel (service FastAPI), tâches ENH-004 et ENH-006

Période des mesures : 5 au 17 octobre 2026
Rédaction : octobre 2026
Document anonymisé : les projets sont désignés « projet A », « projet B »

Résumé exécutif

L'auteur a mesuré, sur une série de bancs d'essai puis sur une tâche réelle, ce que coûtent et ce que valent plusieurs façons de confier du code à des assistants : un modèle Claude seul (Sonnet ou Opus), Codex (OpenAI) seul, des chaînes mixtes (Codex produit, Claude vérifie une fois) et des orchestrations avec sous-agents. Chaque bras est évalué sur son coût Claude en dollars, son nombre de tours, la consommation des jauges OpenAI (5 h et hebdomadaire) et le résultat des tests (échecs et réussites).

≈ ÷ 4 à ÷ 9
coût Claude de la chaîne « Codex + 1 vérification » (0,23 à 0,53 $) contre Sonnet seul (2,01 $) sur la tâche difficile ENH-004

1,3 à 1,45 ×
surcoût de Sonnet + agents par rapport à Sonnet seul (2,57 et 2,89 $ contre 2,01 $)

4,04 $
Opus seul : le plus cher (100 tours, 733 s), 21 échecs, sans gain

14 / 534
Codex seul (B4) : 0 $ Claude mais suite polluée, rien écrit dans 1 essai sur 2

Conclusions chiffrées

- **Bancs bornés (T1 à T10, gros projet) : saturés.** Sonnet seul atteint le plafond de qualité presque partout (par exemple 15/15 puis 14,5/15 en moyenne sur T9, 8/8 sur T3b à 0,27 $). La différence entre bras porte sur le coût, pas sur la qualité.
- **Opus seul n'apporte pas de gain mesuré** : 8/8 à 0,55 $ contre 0,27 $ pour Sonnet sur T3b ; 4,04 $ et 21 échecs sur ENH-004 contre 2,01 $ et 19 échecs pour Sonnet seul.
- **Les sous-agents coûtent plus cher sans gain de note** : environ 1,85 fois le coût de Sonnet seul sur T10 (1,42 $ contre 0,77 $), 1,3 à 1,45 fois sur ENH-004.
- **Codex seul n'est pas fiable sans vérification** : sur ENH-006, 29 échecs contre 8 (pollution de la base de tests partagée) ; sur ENH-004, 14 échecs, et un essai sur deux n'a rien écrit.
- **La chaîne Codex puis UNE vérification Claude est la configuration la plus économique à qualité équivalente** : 0,53 $ et 7 échecs (niveau de base) pour E8 ; 0,23 $ pour E4c ; 0,41 $ sur ENH-006. Coût : de 1 à 8 points de jauge OpenAI 5 h par essai.
- **L'analyse difficile** est le seul cas où un pipeline améliore la qualité : enquête sur un bug de production, 4,17/5 pour « Codex analyse puis Claude » contre 3,0/5 pour Claude seul (3 essais par bras), au prix de jauge OpenAI.

> **Ce qui n'est pas prouvé.** Un gain de productivité « ×3 » n'est pas démontré : il est plausible seulement avec Codex en première passe et vérification courte. La plupart des mesures reposent sur n = 1 ou 2 par bras, sur une seule base de code pour la tâche difficile, avec une variance d'un essai à l'autre parfois aussi grande que l'écart entre bras. Un incident d'outillage (script de tests manquant) invalide un essai et fragilise trois autres résultats (E6, F6, G6).

1. Méthode

1.1 Bras comparés

Bras	Description
A	Sonnet seul (modèle Claude intermédiaire, effort medium).
B	Codex seul (rôle « exécutant » ou chaîne d'analyse Codex puis Sonnet selon le banc ; précisé à chaque tableau).
C	Sonnet + agent « architecte » (Opus) pour l'arbitrage, sans Codex.
D	Sonnet + sous-agents (lecteur, testeur, exécutant, architecte), sans Codex.
E	Codex implémente, puis une seule vérification Claude (Sonnet, sans sous-agents).
F	Opus seul.
G	Opus + sous-agents.

Selon les bancs, la lettre B désigne aussi « analyse Codex (modèle astra, effort medium) puis Sonnet » ; le tableau concerné le précise. Les lettres des bancs plus anciens (ex. T5 : S, C, X) sont conservées telles quelles.

1.2 Mesures

- **Coût Claude en dollars**, relevé sur le coût réel renvoyé par l'outil en mode non interactif.
- **Nombre de tours** (échanges avec le modèle) et **durée** quand elle est disponible.
- **Jauges OpenAI** : fenêtre de 5 h et fenêtre hebdomadaire, en points de pourcentage consommés. Une « sonde » d'une ligne est lancée avant lecture pour éviter une valeur périmée ; la sonde elle-même consomme environ 1 point.
- **Tests** : nombre d'échecs et de réussites de la suite complète, ou note sur un correcteur caché (/5, ou tests figés).

1.3 Conditions et limites générales

- La plupart des bancs n'ont qu'un à trois essais par bras ; la variance n'est donc pas maîtrisée.
- Les consignes générales de l'auteur sont chargées dans tous les bras (biais commun).
- La jauge Claude n'est pas relevable par script ; seule la jauge OpenAI est mesurée.
- Le contrôle d'un gain de qualité repose sur des correcteurs automatiques ; pour les enquêtes, sur une notation par barème et un juge LLM (±0,5 point).

1.4 Mesures préliminaires (économie de tokens)

Avant les bancs comparatifs, des mesures d'optimisation ont posé des repères : Sonnet par défaut réduit le coût d'environ 45 à 50 % à qualité égale (tâche de lecture CSV : 33/33 pour les deux, 0,09 $ contre 0,19 $ pour Opus ; mini-tableur de 73 contrôles : Sonnet 0,18 à 0,19 $, Opus 0,38 à 0,45 $; débogage de 9 bugs sur 5 fichiers : 28/28 partout, 0,13 $ contre 0,29 à 0,35 $). Sur ces tâches, l'ajout systématique d'un architecte (Opus) coûte plus cher sans gain (CSV : 0,20 $; tableur : 0,61 $). Un agent ajoute un tour de contexte supplémentaire. Changer d'effort ou de modèle en cours de conversation recrée tout le cache.

2. Bancs bornés

2.1 T3b : revue d'un corpus difficile (8 bugs dont 4 inter-modules)

Bras	Résultat	Durée	Coût / tokens	Jauge OpenAI
Sonnet seul	8/8	39 s (8 tours)	0,27 $	-
Opus seul	8/8	55 s (8 tours)	0,55 $	-
Codex relecteur (sol, medium)	8/8 + 1 constat en plus (non vérifié)	58 s	18 k tokens, 0 $ Claude	+1 pt
Codex analyste (astra, medium)	8/8, 0 faux positif	86 s	16,7 k tokens, 0 $ Claude	+4 pts

Banc saturé : Opus ne fait pas mieux que Sonnet pour le double du prix. Complément (revue de 6 bugs plantés) : Sonnet 4/6 ; Codex sol medium 3/6, astra medium 4/6, high 5/6, xhigh 6/6. Un corpus à 7 bugs plantés, 3 essais par modèle : Sonnet 3, 5, 4 bugs (0,98 $ en moyenne) ; Opus 7, 5, 4 (2,45 $ en moyenne), soit 0,25 $ par bug trouvé pour Sonnet et 0,46 $ pour Opus.

2.2 T4 : écriture d'un module neuf (spécification précise, 57 tests)

Bras	Résultat	Coût Claude	Remarque
Sonnet seul	57/57, 31 s, 4 tours	0,148 $	-
Codex exécutant (sol low)	57/57, 10,5 k tokens	0 $	+1 pt de jauge OpenAI

Effort de Sonnet (2 essais par niveau) : low 57/57 à 0,147 et 0,113 $; medium 57/57 à 0,111 et 0,280 $; high 57/57 à 0,140 et 0,159 $. La qualité est identique ; le coût varie davantage entre deux essais du même niveau (×2,5 à medium) qu'entre niveaux. Codex exécutant : 57/57 deux fois, +1 pt chacune. Le rôle « relecteur » (lecture seule) ne peut pas écrire : échec attendu, non compté.

2.3 T5 : lot de 10 tâches bornées (140 tests figés)

Bras	Chaîne	Résultat	Coût Claude	Jauge OpenAI
S	Sonnet medium seul	140/140	1,07 $	0
C	Codex exécutant (sol low) seul	140/140	0 $	5 h : 0 à 5 % ; hebdo 38 %
X	C puis vérification Sonnet	140/140	1,46 $	-

Saturé : seul le coût départage. Sur tâche bornée à spécification précise, un correcteur automatique remplace la vérification ; la chaîne X (vérification en plus) est la pire en coût, sans rien avoir corrigé.

2.4 T6 : bug de concurrence (2 bugs, note 0 à 2, 3 essais par bras Claude)

Bras	Note (3 essais)	Coût par essai
Sonnet medium	2/2 ×3	0,12 à 0,16 $
Sonnet high	2/2 ×3	0,14 à 0,18 $
Opus medium	2/2 ×3	0,19 à 0,50 $

Saturé : Sonnet medium suffit. Le bras Codex n'a pas été lancé (jauge).

2.5 T7 : effet de la longueur du fichier de consignes de Codex (3 essais par bras, 57 tests)

Fichier de consignes	Réussite à 57/57	Tokens	Checklist suivie
Aucun	3/3	≈ 11 k	0 fois
Court	3/3	≈ 19 k	3/3
Long	1/3 (2 essais avec code cassé : TypeError)	≈ 27 k	3/3

Un fichier long coûte environ 2,4 fois plus de tokens et semble dégrader (n = 3, à confirmer) ; le court coûte 1,7 fois pour une discipline sans gain de qualité mesuré. Biais : un fichier de consignes global est chargé dans tous les bras.

2.6 T8 : trois problèmes techniques durs (1 run par bras)

A = Sonnet seul ; B = analyse Codex (astra, medium) puis Sonnet. Notes /5 par correcteur caché.

Tâche	A note / $	B note / $	Jauge 5 h (B)
h1 contradiction	5 / 0,219	5 / 0,212	+3
h2 bug profond	5 / 0,156	5 / 0,224	+3
h3 invariant multi-fichiers	5 / 0,187	5 / 0,265	+3
Total	**15/15 / 0,56 $**	**15/15 / 0,70 $**	**+9 pts**

Banc saturé. Dans h1, la contradiction a été signalée dans le rapport et le test laissé rouge (aucun contournement). Le pipeline B est plus cher (+0,14 $, +9 pts) sans gain de qualité.

2.7 T9 : trois tâches plus dures (bras A, C, B ; 2 runs)

A = Sonnet seul ; C = Sonnet + architecte (Opus, sans Codex) ; B = analyse Codex (astra medium) puis Sonnet.

Tâche	A (n1 / n2)	C (n1 / n2)	B (n1 / n2)
h4 concurrence	5 / 5 (0,41 / 0,31 $)	5 / 4 (0,51 / 0,60 $)	5 / 4 (0,20 / 0,31 $)
h5 refonte de 8 fichiers	5 / 5 (0,53 / 0,58 $)	**0 / 0** (0,88 / 0,70 $)	5 / 5 (0,49 / 0,56 $)
h6 deux bugs + test faux	4 / 4 (0,19 / 0,19 $)	4 / 4 (0,44 / 0,42 $)	3 / 3 (0,26 / 0,22 $)
Total n1	15 / 1,13 $	10 / 1,83 $	14 / 0,96 $ (+10 pts)
Total n2	14 / 1,08 $	8 / 1,72 $	12 / 1,09 $
Moyenne 2 runs	**14,5**	**9**	**13**

Note h6 : +1 point ajouté à la main pour tous les bras (contradiction signalée dans le rapport). **Incident h5 / bras C (0/5 deux fois)** : l'architecte a imposé une étape 0 (générer d'anciens fichiers de données avec une commande Python), refusée en mode non interactif (seul l'outil de tests était autorisé) ; l'exécutant fut bloqué aussi ; Sonnet s'est arrêté sans rien modifier. C'est un défaut de protocole (plan exigeant une commande non autorisée et renoncement au lieu d'adaptation), pas une erreur de code. Pour B, une régression constante sur h6 (1 rouge de plus). C coûte environ 1,6 fois A.

2.8 T10 : banc agents (3 tâches × 3 bras × 2 runs)

A = Sonnet seul ; D = Sonnet + agents (lecteur, testeur, exécutant, architecte, sans Codex) ; B = analyse Codex (astra medium) puis Sonnet. Coût moyen sur 2 runs.

Tâche	A (note / $)	D	B (jauge OpenAI 5 h / run)
h7 bug dispersé (61 modules)	5 / 0,26	5 / 0,38	5 / 0,21 (+4 à 5)
h8 suite verbeuse (316 k caractères)	4 / 0,20	4 / 0,38	4 / 0,24 (+5 à 6)
h9 migration de 17 modules	5 / 0,31	5 / 0,66	5 / 0,33 (+4)
Total (somme des moyennes)	**14 / 0,77**	**14 / 1,42**	**14 / 0,78**

Qualité identique partout. D coûte environ 1,85 fois A sans gain de note (démarrage des agents, deuxième contexte). B coûte en dollars Claude comme A mais consomme 4 à 6 points de jauge OpenAI par run. Banc encore saturé (h8 : 4/5 pour tous, un point de contradiction non obtenu). Biais : jauge Claude non relevée, sondes de jauge consommant un peu d'OpenAI, 2 runs seulement.

3. Enquête difficile : bug de production du projet B

Cas réel : « le conteneur plante après plusieurs jours » (projet B). Le barème compte 5 points correspondant au correctif réel : délai d'attente de stockage objet infini, tâches périodiques (chevauchement et isolement des erreurs), processus zombies, rotation des journaux, chien de garde.

3.1 Premier essai (12/10, un essai par bras)

Bras	Chaîne	Note /5	Coût Claude	Jauge OpenAI 5 h
A	Claude seul	≈ 3	0,31 à 0,40 $	0
C	allers-retours	≈ 2,5	0,37 $	+11
D1	astra high puis Claude	5	0,276 $	+30
D2	astra medium puis Claude	4	0,347 $	+15
E1	pipeline à jour, Codex bloqué (redirection)	≈ 3 (invalide)	0,893 $	0
E2	orchestration libre (analyste + 2 Haiku + architecte)	4	1,532 $	+8
E3	pipeline à jour + règles anti-agents	≈ 3,5	0,285 $	+13

3.2 Répétition (14/10, 3 essais par bras, juge LLM)

Bras	Notes /5 (coût Claude)	Moyenne
A : Claude seul	2,5 (0,59 $) · 3,5 (0,47 $) · 3 (0,39 $)	3,0 / 0,48 $
D : astra medium puis Claude	4,5 (0,43 $) · 3,5 (0,33 $) · 4,5 (0,29 $)	**4,17 / 0,35 $** + 69 à 102 k tokens Codex par essai
E : règles à jour	3,0 (0,50 $) · 3 (0,55 $) · 2,5 (0,29 $)	2,83 / 0,45 $

D est le seul bras au-dessus de Claude seul (+1,2 point, moins cher côté Claude) mais consomme de la jauge OpenAI : le lot de 9 essais a fait passer la jauge 5 h d'environ 23 % à 93 % (hebdomadaire : 37 %). Le juge LLM est unique (±0,5).

3.3 Rejeu antérieur avec Opus, Sonnet et contre-expertise

Essai	Coût	Note /5
Opus 1 / 2	1,21 $ / 1,67 $	3 / 3
Sonnet 1 / 2	0,61 $ / 0,83 $	2,5 / 3,5
Sonnet + contre-expertise architecte	1,81 $ (0,87 + 0,94)	2,5

Opus 3/5 pour 1,44 $, Sonnet 3/5 pour 0,72 $: la variance entre essais égale l'écart entre modèles. L'architecte a **écarté à tort** deux vraies causes. Aucun bras n'a trouvé le délai d'attente de stockage sans reproduction réelle : le levier d'une enquête est la mesure (journaux, reproduction), pas le modèle.

4. Projet A (service FastAPI) : banc « gros projet »

Deux tâches (analyse multi-fichiers et petite modification) sur le backend d'un service FastAPI ; juge : un test écrit à l'avance (9 cas, 6 échecs avant, 3 réussis). Bras A : Sonnet medium seul. Bras B : analyste Codex (astra medium) puis exécutant (sol low) puis vérification Claude.

	A : Sonnet seul	B : Codex puis vérification
Test juge	9/9	9/9
Suite existante (545 tests)	538 réussis, 7 échecs identiques	538 réussis, 7 échecs identiques (origines WebSocket, non vérifiés sur l'original)
Coût Claude	0,47 $ (31 tours)	≈ 0 $ hors vérification (diff et tests)
Jauge OpenAI	0	5 h : +10 pts ; hebdo : +1
Temps	133 s	163 s (126 d'analyse + 27 d'exécution)

Qualité égale (diffs de taille équivalente : 56 lignes pour A, 44 pour B, B plus propre). La chaîne Codex économise environ 0,47 $ Claude pour environ 10 points de jauge 5 h sur ce projet.

5. Tâches ENH-006 et ENH-004 (projet A) : grandeur nature

Base : copie du backend du projet A, **7 échecs préexistants** sur 538 réussis. Un prompt unique par tour.

5.1 Tour 1 : ENH-006 (limiteur par session et par lot, difficulté moyenne)

Bras	$ Claude	Tours	Durée	OpenAI 5 h	Suite complète	Remarque
A Sonnet seul	0,64	22	168 s	0	8 échecs (7 + 1 imposé par le plan) / 559 réussis ; 22 tests ajoutés	propre
B Codex exécutant seul	0	-	118 s	+1	29 échecs / 520 réussis	ses nouveaux tests polluent la base partagée (sans eux : 8 échecs) ; il n'a pas pu lancer la suite (script de tests planté dans son bac à sable)
D Sonnet + agents	0,89	8	206 s	0	8 échecs / 555 réussis	propre
E1 Codex puis vérification Claude	0,41	21	207 s	≈ +1	8 échecs / 541 réussis	Claude a corrigé la pollution laissée par Codex

A et D sont équivalents en qualité (D 1,4 fois plus cher). B n'est pas cher mais présente un défaut réel non vu faute de pouvoir lancer la suite. E1 coûte 0,41 $ contre 0,64 $.

6. Chapitre central : ENH-004 (tâche difficile : éviction LRU, rétention, replay paginé)

Tâche difficile du projet A. Particularité : les 7 tests existants du *replay* paginé contredisent le plan (liste JSON contre objet {total, offset, limit, entries} ; plafond 2000 contre 1000). Un bras qui les laisse rouges est conforme au plan, pas fautif. Les échecs de base préexistants sont **7**.

6.1 Tour 2 : A4, D4, B4, E4, E4c

Bras	$ Claude	Tours / durée	Échecs / réussis	Remarque
A4 Sonnet seul	2,01	94 tours, 539 s	19 / 555	7 connus + 12 contredits (replay ×6, éviction ×3, rétention ×3), laissés rouges ; sans pollution
D4 Sonnet + agents	≈ 2,89	-	8 / 563	tests contredits adaptés ; 1 échec en plus (*test_eviction_is_transparent_to_state*) ; JSON final perdu (limite de session), chiffre approximatif
B4 Codex seul	0	-	14 / 534	7 connus + replay ×7 (contredits) ; +4 pts OpenAI ; pas de script de tests dans son bac à sable
E4 Codex (prompt amélioré)	0	-	7 / 538	Codex n'a RIEN écrit (contrat « à trancher ») : **invalide** ; +1 pt OpenAI
E4c = B4 + vérification Claude	0,23	16 tours, 74 s	14 / 534	Claude : « rien d'important de cassé », aucune correction

Incidents : limite de session Claude atteinte (D4 et E4 en erreur d'API, reprise à 14 h) ; E4b mal copié (0,14 $ perdus).

6.2 Tour 3 (16/10) : E6, D7, F6, G6

> **Incident d'outillage.** Le script de tests (« pt.sh ») manquait dans les copies D6, E6, F6 et G6 pendant le tour. D6 est **invalide** (arrêté sans rien écrire) et a été refait en D7 avec le script. Les résultats E6, F6 et G6 sont à prendre avec prudence.

Bras	$ Claude	Tours	Durée	Échecs / réussis
E6 Codex + vérification Claude (consigne « laisse-les rouges »)	0,22	19	-	20 / 527
D7 Sonnet + agents	2,57	3 (agents)	50 s	14 / 560
F6 Opus seul	4,04	100	733 s	21 / 548
G6 Opus + agents	3,44	24	320 s	9 / 559

Durées de D7, F6, G6 : 50 s, 733 s, 320 s telles que transmises pour cette synthèse. Références du tour 2 : A4 2,01 $ (19 / 555), D4 ≈ 2,89 $ (8 / 563). n = 1 par bras ; diffs non relues ; jauges OpenAI non lues pour ce tour.

Le « 20 échecs » de E6 vient de la consigne « laisse-les rouges » (même convention que A4 : 19), pas d'une faute de qualité.

6.3 E8 (17/10) : Codex adapte les tests contredits, la vérification Claude adapte aussi

Bras	$ Claude	Tours / durée	Échecs / réussis	OpenAI
E8 Codex + vérification Claude	0,53	22 tours, 101 s	**7 / 545** (= seuil de base)	+8 pts (5 h), +1 (hebdo)
E9 retest de E8 (17/10)	0,33	16 tours, 82 s	**7 / 543** (= seuil de base)	+13 pts (5 h), +2 (hebdo)

Moins de tests ajoutés que D7 et G6. Les tests demandés par le plan mais **absents** : restauration transparente après éviction (égalité d'état), course éviction / événement, mise à jour de l'activité aux 3 endroits, taille de page du replay, plan de requête (EXPLAIN QUERY PLAN), démarrage et arrêt du nettoyeur de sessions. Cela explique l'écart de couverture avec D7 et G6.

Relecture de la diff de E8 (relecteur Sonnet, lecture seule, rien exécuté)

- Toutes les exigences de code du plan sont réalisées (réglages, index, éviction LRU/TTL, nettoyeur de sessions, replay paginé, câblage).
- Aucun défaut de gravité HIGH ou CRITICAL (confiance > 80 %). Mineurs : une session sans ligne en base n'est jamais évincée par le TTL ; le *total* du replay compte les enregistrements bruts.
- Tests existants adaptés au nouveau contrat sans affaiblissement réel ; un test passe de « limit=99999 → 200 » à « → 422 » (voulu).
- Écart non demandé : un ancien réglage (inactivité 6 h) remplacé par un TTL d'1 h, éviction limitée aux sessions terminées.

6.4 Synthèse ENH-004

Bras	$ Claude	Échecs	Réussis	Total tests	Rapport au coût de A4
A4 Sonnet seul	2,01	19	555	574	1,00
D4 Sonnet + agents	≈ 2,89	8	563	571	≈ 1,44
D7 Sonnet + agents	2,57	14	560	574	1,28
B4 Codex seul	0	14	534	548	0
E4c Codex + vérif.	0,23	14	534	548	0,11
E6 Codex + vérif. (« rouges »)	0,22	20	527	547	0,11
F6 Opus seul	4,04	21	548	569	2,01
G6 Opus + agents	3,44	9	559	568	1,71
E8 Codex + vérif. (adapte)	0,53	7	545	552	0,26

Colonnes « Total tests » et « Rapport » calculées par l'auteur du rapport (somme et division) ; elles ne figurent pas telles quelles dans les sources. La source mentionne « 553 » comme total pour E8 ; la somme 7 + 545 donne 552 (écart d'une unité non expliqué).

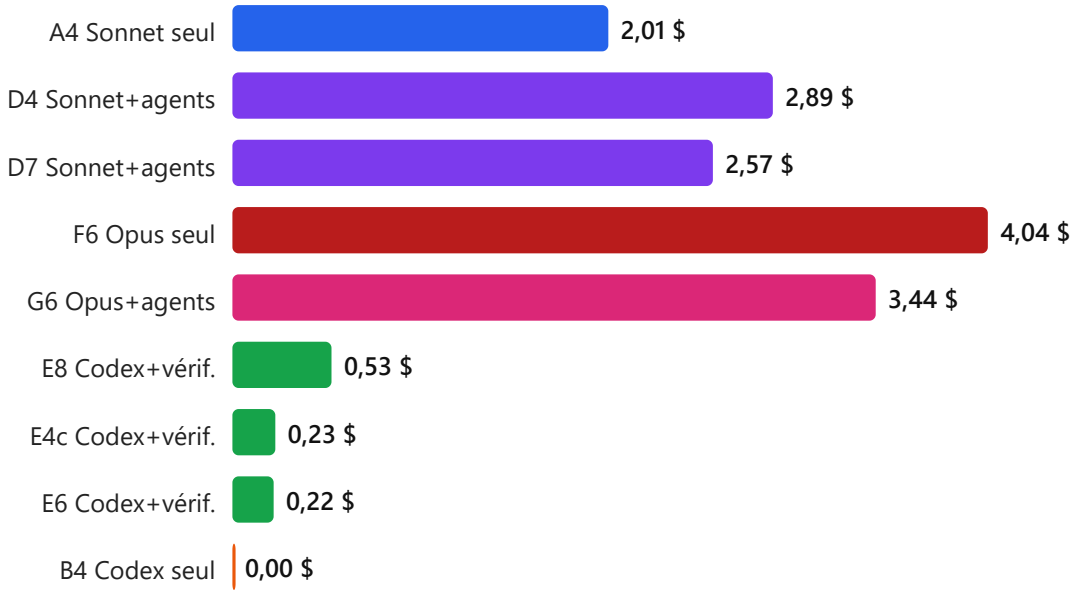


Figure 1. Coût Claude ($) par bras sur ENH-004 (tours 2 et 3). D4 : chiffre approximatif.

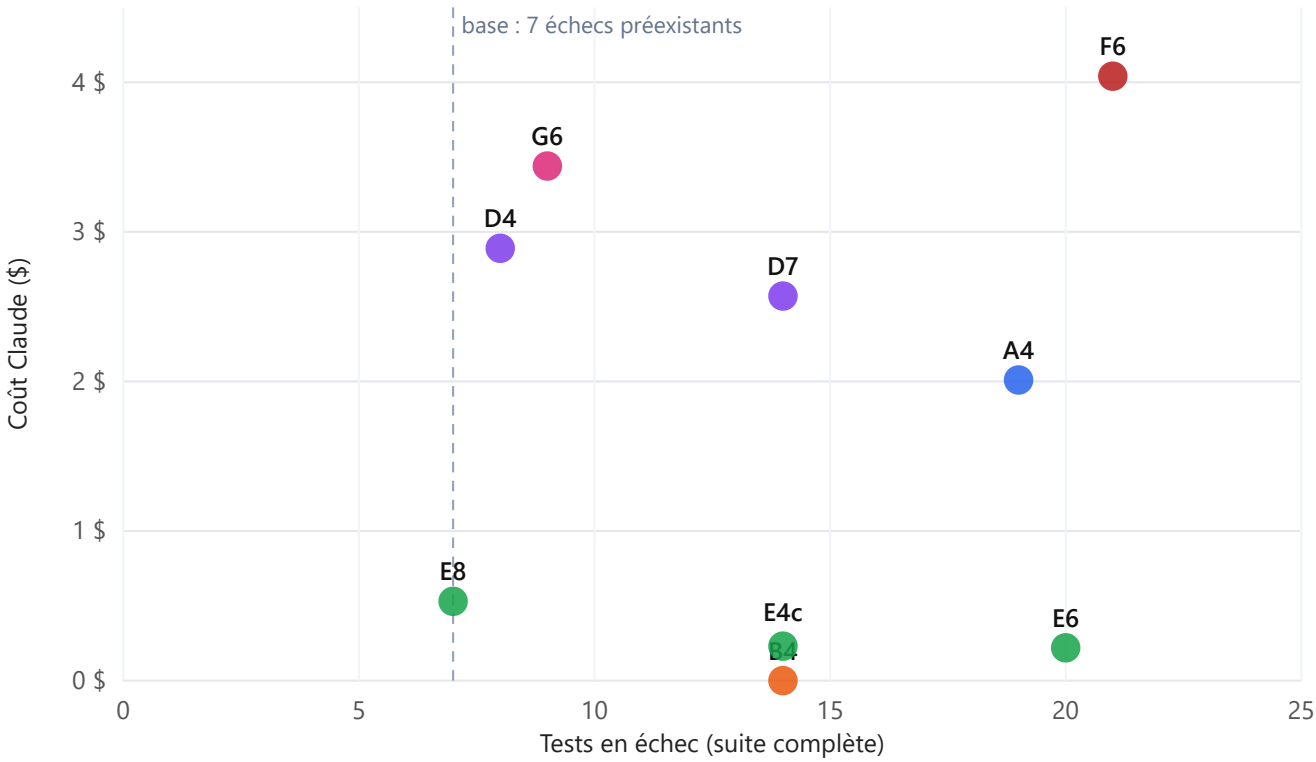


Figure 2. Coût Claude contre nombre d'échecs de la suite complète (ENH-004). Le bas et la gauche du graphique sont préférables. Le trait pointillé marque les 7 échecs préexistants. Les échecs « contredits » laissés rouges par convention (A4, E6) ne sont pas des fautes.

Lecture. Les bras Codex + vérification (E4c, E6, E8) occupent le coin « peu cher » (0,22 à 0,53 $) ; E8 atteint même le niveau de base de 7 échecs. Sonnet seul (A4) et Sonnet + agents (D4, D7) se situent à 2 à 3 $; Opus (F6, G6) à 3,4 à 4 $. Condition de la chaîne Codex : la consigne demande d'**adapter** les tests contredits sans les affaiblir et de les lister ; une consigne « laisse-les rouges » redonne le niveau de A4 (20 échecs).

7. Conclusions

7.1 Ce qui est prouvé (dans les limites de n)

- **Sur ENH-004, le coût Claude de la chaîne Codex + une vérification est divisé par environ 4 à 9 à qualité de tests équivalente** (0,23 à 0,53 $ contre 2,01 $ pour Sonnet seul ; la source parle de ≈ 9 × moins pour E4c, 2-3 $ contre 0,2-0,5 $ au total).
- **Sonnet + agents coûte environ 1,3 à 1,45 fois Sonnet seul** (2,57 et 2,89 $ contre 2,01 $) sur ENH-004, et environ 1,85 fois sur T10 ; aucune amélioration de note sur les bancs bornés.
- **Opus seul est le plus cher sans gain** : 4,04 $ et 21 échecs, 100 tours, contre 2,01 $ et 19 échecs pour Sonnet seul.
- **Codex seul n'est pas fiable sans vérification** : pollution d'état (29 échecs contre 8 sur ENH-006), 14 échecs sur ENH-004, une réponse sans fichier modifié dans un essai sur deux.
- Les bancs bornés sont **saturés** : ils ne départagent pas les bras sur la qualité.
- L'**enquête difficile** profite d'une analyse Codex (astra medium) suivie de Claude : 4,17/5 contre 3,0/5 sur 3 essais.

7.2 Ce qui n'est pas prouvé

- Un **gain de productivité × 3** : plausible seulement avec Codex en première passe et vérification courte ; non démontré (n = 1).
- La généralisation : **n = 1 ou 2 par bras**, **une seule base de code** pour la tâche difficile, variance d'un essai à l'autre non mesurée.
- La couverture de tests de la chaîne Codex : E8 omet des tests demandés par le plan (voir 6.3).
- La fiabilité de Codex : un essai sur deux n'écrivait rien avant l'ajout d'une consigne explicite.

7.3 Recommandations

Avec un abonnement OpenAI disponible

- Par défaut, Sonnet seul pour les tâches courantes.
- Pour une tâche difficile à plusieurs fichiers : **Codex implémente, puis une seule vérification Claude sans sous-agents**, chaîne linéaire sans aller-retour. La consigne doit : demander d'adapter les tests contredits sans les affaiblir et de les lister ; imposer une commande de tests directe (pas un script absent du bac à sable) ; préciser qu'« une réponse sans fichier modifié est un échec ».
- Pour l'analyse difficile : analyste Codex (astra medium) par défaut, enquêteur (astra high) pour l'enquête à enjeu ; jamais xhigh (≈ 2 fois le coût pour environ 1 bug de plus).
- Vérifier que les tests demandés par le plan sont présents ; relire la diff.
- Surveiller la jauge OpenAI (de 1 à 8 points de la fenêtre 5 h par essai ici).

Sans abonnement OpenAI

- Sonnet seul ; l'architecte (Opus) seulement à des déclencheurs précis (test rouge après 2 corrections, contradiction, bug profond), avec un plan limité aux commandes réellement autorisées et un repli.
- Éviter les sous-agents pour les tâches bornées (surcoût de 1,3 à 1,85 fois sans gain).
- Ne pas utiliser Opus seul par défaut.

8. Limites et biais

- **Échantillons minuscules** : n = 1 à 3 par bras ; le coût de Sonnet varie d'un facteur 2,5 entre deux essais identiques (T4, effort medium).
- **Une seule base de code** (projet A) pour la tâche difficile ; autres bancs sur des corpus synthétiques.
- **Notation** : correcteurs automatiques sur la plupart des bancs ; enquête notée par barème et un juge LLM unique (±0,5) ; E8 relu par un relecteur Sonnet sans exécution.
- **Incidents** : limite de session Claude atteinte (D4 coût approximatif, E4 invalide) ; script de tests manquant (D6 invalide ; E6, F6, G6 à prendre avec prudence) ; E4b mal copié ; E1 de l'enquête invalide (Codex bloqué).
- **Diffs non relues** pour la plupart des bras du tour 3 ; jauges OpenAI non lues pour ce tour.
- **Jauges** : jauge Claude non scriptable ; usage OpenAI parallèle de l'auteur qui bruite les relevés ; sondes consommant un point.
- **Environnement** : fichier de consignes global chargé dans tous les bras ; limites de quotas OpenAI modifiées le 29/09/2026, à remesurer.
- **Contradiction de tests** : la convention « tests contredits laissés rouges » (A4, E6) rend les comptes d'échecs non directement comparables à ceux des bras qui les adaptent.

Annexe : rôles Codex et réglages

Rôle	Réglage
lecteur	gpt-6-luna, effort low, lecture seule
chercheur	luna low + recherche web
exécutant	gpt-6-sol, effort low, écriture dans l'espace de travail
relecteur	sol, effort medium, lecture seule
architecte	astra, effort high (avis dur, avec parcimonie : quota)
analyste	astra, effort medium, lecture seule (enquête courante)
enquêteur	astra, effort high, lecture seule (enquête difficile ; plafond, jamais xhigh)

Table provisoire issue des séries 4 à 6. Le niveau xhigh est exclu par décision de l'auteur.

Principes d'usage retenus

- Une tâche = une session Codex, modèle explicite ; une seule chaîne de tests à la fois ; sous-agents Codex désactivés.
- **Chaîne linéaire** : Codex fait une passe (analyse, relecture ou code), Claude vérifie ou complète une fois, sans renvoi. Claude relit les lignes citées et ne rejette un constat qu'en le démontrant faux.
- Jamais accepter le code de Codex tel quel : lire les fichiers voisins, lancer le code et les tests, rapporter en tête les commandes lancées et non lancées.
- Codex est « un plus, jamais une dépendance » : avant chaque étape, vérifier présence, connexion et quota ; sinon, passer au pipeline Claude seul.
- Quota OpenAI : fenêtres 5 h et hebdomadaire partagées entre tous les usages ; sonde fraîche avant lecture ; budget ≈ +25 points depuis une jauge fraîche (+10 à +12 pour un simple test) ; viser environ 10 % restant en fin de session lourde.
- Commande type : exécution non interactive avec écriture dans l'espace de travail, sandbox Windows non élevé, sortie JSON, entrée standard vide.
- Réglage du cache : durée du cache 1 h sur le fil principal, 5 min pour les agents : un agent ne doit pas attendre plus de 5 min une commande longue.
- Plan d'un architecte : uniquement des commandes que la session peut lancer, avec un repli ; si une commande est refusée, adapter plutôt que s'arrêter.